רוני מינדלין מילר 302242870
מיה קרמר 204219976

למידה עמוקה עבודה 3

Data exploration:

הבעיה: הנתונים מתייחסים לנתוני חיפוש ותוצאות שלקוחות ביצעו ברשת Home Depot. עבור כל רשומה בנתונים הכוללת את הכותרת של המוצר אותו חיפש הלקוח ותיאור התוצאה שהתקבלה, דירגו את הרלוונטיות של התוצאה לחיפוש ע"י ביצוע מבחן בו 3 שופטים התבקשו לדרג את הרלוונטיות של התוצאה לחיפוש ע"י אחד משלושת הדירוגים:

- Irrelevant (1)
- Partially or somewhat relevant (2)
- Perfect match (3)

לבסוף לקחו את הממוצע של שלושת הדירוגים. כך קיבלנו את ערך הרלוונטיות לכל רשומה שנע בטווח 1-3 כאשר יש בדיוק 13 ערכים אפשריים. ניתן להתייחס לבעיה כבעיית רגרסיה בכך שיש לחזות את הרלוונטיות של התוצאה לשאלה על ידי מספר בין 1 ל-3, לעומת זאת ניתן להתייחס לבעיה כבעיית סיווג בכך שיש לסווג כל זוג של חיפוש-תוצאה לאחד מ-13 ערכי הרלוונטיות השונים. אנו ניסינו להתייחס לבעיה ב-2 האופנים האלו כפי שנתאר בהמשך.

זאת אומרת שה-label של כל זוג (ביטויי חיפוש, תוצאות חיפוש) הוא בעצם מידת ההתאמה של תוצאת החיפוש לביטוי החיפוש המבוטאת במספר בין 1 ל-3 כאשר 3 מתאר את מידת ההתאמה הגבוהה ביותר ו-1 מתאר את מידת ההתאמה הנמוכה ביותר.

הנתונים מחולקים ל-2 קבצים עיקריים- train, test כך שtrain מכיל 74067 רשומות וtest מכיל 166693. בהסבר על הנתונים בkaggle היה נתון שיש חיפושים בtest שכבר המודל ראה בעבר בtrain אך גם כאלו שלא ראה בעבר. בדקנו מהו מספר הsearch_items הייחודיים בtrain ובtest:

```
train unique search terms 11795
test unique search terms 22427
```

זאת אומרת שבוודאות נתקל בלפחות 10,632 ביטויי חיפוש ב-test שלא נתקלנו בהם בעבר ונצטרך לחזות בצורה הטובה ביותר את ההתאמה שלהם לתוצאת החיפוש שלהם.

לא קיימים ערכים חסרים בנתונים.

התפלגות הנתונים:

- התפלגות המוצרים שהחיפוש מחזיר בקובץ train:

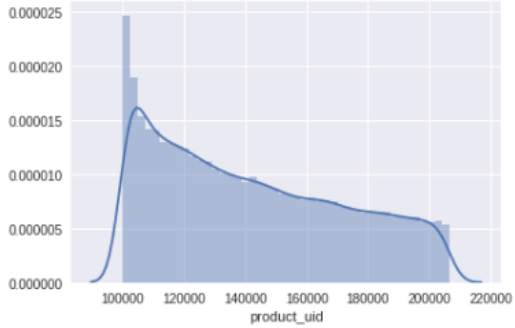

- התפלגות המוצרים שהחיפוש מחזיר בקובץ test:

רוני מינדלין מילר 302242870
מיה קרמר 204219976

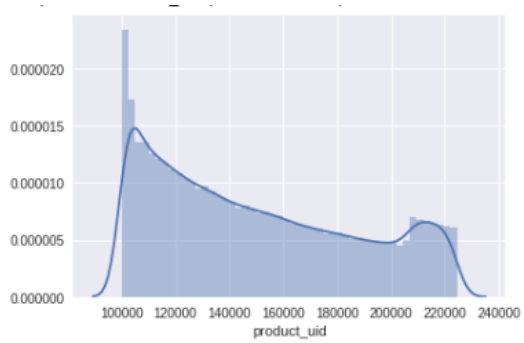

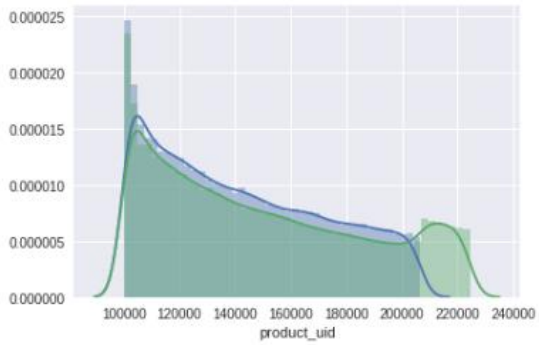

ניתן לראות שהתפלגות המוצרים שהחיפוש מחזיר בקבצי הtrain וה-test דומה כלומר כנראה שאנשים מחפשים לרוב את אותם המוצרים או לחלופין שהמערכת מחזירה לרוב את אותם המוצרים גם עבור חיפושים שונים (פחות סביר מאחר וציון ההתאמה של רוב החיפושים הוא לרוב ציון טוב) או שילוב של השניים.

בדקנו כיצד מתפלגים ציוני ההתאמה של המוצרים:

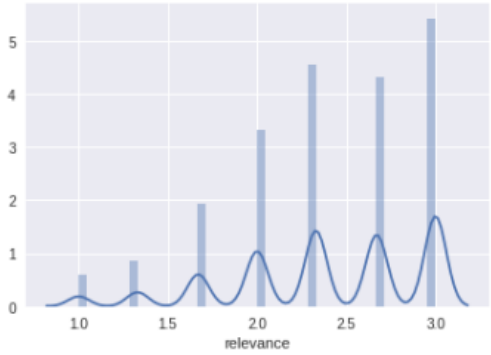

כפי שציינו לעיל, רוב החיפושים מסתיימים בתוצאות מאוד טובות (ציון התאמה בטווח 2.5-3), חלק גדול מהחיפושים מסתיימים בתוצאה בינונית (ציון התאמה בטווח 2-2.5) ומעט חיפושים מסתיימים בתוצאות לא טובות (ציון התאמה בטווח 1-2). זאת אומרת ש**הנתונים הם imbalanced** ולכן בהמשך נשתמש בשיטות להתמודד עם בעיה זו. כמות סיווגים לכל class:

רוני מינדלין מילר 302242870
מיה קרמר 204219976

```
3.00    19125
2.33    16060
2.67    15202
2.00    11730
1.67     6780
1.33     3006
1.00     2105
2.50       19
2.25       11
2.75       11
1.75        9
1.50        5
1.25        4
```

ניתן לראות שמעט מאוד רשומות קיבלו את הדירוגים: 2.5, 2.25, 2.75, 1.75, 1.75, 1.5, 1.25

חלק 1- Character level LSTM

הערה: בראשית הדרך חיברנו בין שדה title ושדה product_description עבור כל מוצר על מנת לנסות לקבל כמה שיותר מידע על המוצר. עם זאת לאחר התייעצות עם נתי ומאחר והריצה הייתה מאוד ארוכה עד כדי כך שלא הצלחנו לקבל תוצאות בזמן סביר החלטנו לא להשתמש בשדה product_description על מנת שנוכל לשפר את המודל ולנסות מודלים נוספים הרצים בזמן סביר מאשר הרצה של מודל עיקרי אחד בזמן לא סביר. בנוסף ניסינו להוסיף חלק מה-product_description (לקחנו את כל 400 התווים הראשונים) אך זה לא שיפר את תוצאות המודל וגרם לכך שזמן האימון יהיה ארוך יותר. להלן דוגמה לאחד ה-epochs שהתקבלו:

```
Train on 59251 samples, validate on 14816 samples
Epoch 1/5
59251/59251 [==============================] - 84s 1ms/step - loss: 0.9543 - val_loss: 0.2874
Epoch 2/5
59251/59251 [==============================] - 82s 1ms/step - loss: 0.2857 - val_loss: 0.2851
Epoch 3/5
59251/59251 [==============================] - 83s 1ms/step - loss: 0.2858 - val_loss: 0.2851
Epoch 4/5
59251/59251 [==============================] - 82s 1ms/step - loss: 0.2860 - val_loss: 0.2851
Epoch 5/5
59251/59251 [==============================] - 82s 1ms/step - loss: 0.2856 - val_loss: 0.2851
rmse 0.5339770017852502
```

Preprocess:

ראשית יצרנו data frame בשם all_df שהיא בעצם חיבור של שתי ה-data frames של הtrain והtest על מנת להכין את הנתונים על בסיס תווים הנמצאים בכל הנתונים. חילקנו את הטקסט בשדות search_trem ו-proudct_title לתווים והסרנו תווים שלאחר מעבר על הנתונים הגענו למסקנה שאינם מוסיפים מידע אלא עשויים לגרום לרעש. התווים אותם הסרנו:

```
char_to_remove = [' ', '{', '}', '"', '(', ')', '.', ',', '&','[',']','`','_','\', '~', '\\'
                  '\x80', '\x81', '\x84', '\x89', '\x8b', '\x90', '\x93', '\x95', '\x99', '\x9a',
                  '\x9d', '\xa0', '¡', 'Ç', 'ª', 'À', 'Â', 'È', 'Ê', 'Ë', 'Ï', 'Ô', 'Ù',
                  'Ü', 'à', 'ã', 'å', 'è', '÷']
```

רוני מינדלין מילר 302242870
מיה קרמר 204219976

התווים הייחודים שנותרו:

```
array(['<uniq>', '!', '#', '$', '%', '*', '+', '-', '/', '0', '1', '2',
       '3', '4', '5', '6', '7', '8', '9', ':', ';', '=', '?', '\\', 'a',
       'b', 'c', 'd', 'e', 'f', 'g', 'h', 'i', 'j', 'k', 'l', 'm', 'n',
       'o', 'p', 'q', 'r', 's', 't', 'u', 'v', 'w', 'x', 'y', 'z', '\x80',
       '°', '²'], dtype='<U6')
```

את התו '<uniq>" אנו הוספנו על מנת לתאר את ה-padding ב-0 שיתווסף בהמשך.

לאחר החלוקה לתווים המרנו כל תו למספר באמצעות label encoder ובכך קיבלנו עבור כל רשומה שתי מערכים של מספרים, אחד עבור הsearch_term ואחד עבור הproduct_title.

כעת בדקנו מהו האורך המקסימלי של כל המערכים שהתקבלו (מספר תווים מקסימלי) תחת הפיצ'רים search_term ו-product_title ובכך קיבלנו שתי ערכים prod_max_len=128 ו-search_max_len=58.

ביצענו padding של אפסים בתחילת כל מערך על מנת שכל המערכים השייכים לאותו פיצ'ר יהיו באותו האורך. קבענו שאורך המערכים יהיה כאורך המקסימלי (כלומר prod_max_len ו-search_max_len בהתאמה). יש לציין שגם ניסינו לבצע padding לאורך הממוצע של המערכים (וחיתוך למערכים הארוכים מהאורך הממוצע) אך קיבלנו תוצאות מעט פחות טובות ולכן בחרנו להשאיר את ה-padding לאורך המקסימלי. בנוסף נרצה לציין שלא רצינו לבחור ערך זהה לאורך המערכים של שתי הפיצ'רים search_term ו-product_title מאחר ואורך הtitle גדול יותר מאשר אורך הsearch (בערך פי 2) ולא רצינו להוסיף יותר מידי אפסים (בתהליך הpadding) שעלולים לגרום לרעש בנתונים.

<u>Model-based benchmark</u>

כעת בנינו את המודל הראשון והבסיסי המתייחס לרמת התווים:

- תחילה ניסינו להשתמש בערך ה-relevance הממוצע של הtrain עבור הערך החזוי. התוצאות שהתקבלו:

	MAE	RMSE
train	0.440	0.530
test	0.441	0.536
val	0.493	0.522

- לאחר מכן ניסינו להשתמש במערכי רצפי התווים ולחשב את מספר התווים המשותפים בין שדה ה-product_title לשדה ה-search_term . את ערך ההתאמה המשוער חישבנו באמצעות הנוסחה הבאה:

$$\frac{(num\ of\ chars\ title\ \cap num\ of\ chars\ search) * 3}{num\ of\ chars\ title\ \cup num\ of\ chars\ search}$$

השגיאות שהתקבלו היו גבוהות:

	MAE	RMSE
train	1.044	1.187
test	1.351	1.46
val	0.760	0.897

רוני מינדלין מילר 302242870
מיה קרמר 204219976

כפי שציינו קודם, מסקירת קובץ נתוני האימון ניכר כי לרוב שדות ה-product_title ארוכים יותר משדות ה-search_term. בנוסף, ניתן לראות כי הרבה מהרשומות, כאשר כל המילים אשר נמצאות ב-search_term מופיעות גם ב-product_title, מידת ההתאמה (relevance) היא מקסימלית (3), גם כאשר שדה ה-product_title מכיל מילים נוספות. מכאן אנו מסיקות כי קיימת חשיבות לקיום מילים משותפות בין שני השדות **ביחס למילים המופיעות ב-search_term .** יחס זה כנראה יהיה רלוונטי גם עבור התווים, ולכן התחשבנו בכך בחישוב ההתאמה. לפי הנוסחה הבאה:

$$\frac{(num\ of\ chars\ title\ \cap num\ of\ chars\ search) * 3}{num\ of\ chars\ search}$$

שינוי זה אכן שיפר את התוצאות:

	MAE	RMSE
train	0.481	0.667
test	0.480	0.631
val	0.622	0.787

- באותו האופן בחנו את ה-NGrams המשותפים ע"י שימוש ב-count vectorizer . החישוב נעשה לפי הנוסחה הבאה:

$$\frac{(num\ of\ n\ grams\ title\ \cap num\ of\ n\ grams\ search) * 3}{num\ of\ n\ grams\ search}$$

התוצאות הטובות ביותר התקבלו עבור NGrams באורך 2, אך היו פחות טובות מהשיטות הקודמות:

	MAE	RMSE
train	0.704	0.881
test	0.541	0.722
val	0.584	0.728

<u>Siamese network - Character level LSTM</u>

שיטת ולידציה ראשונית: חלוקה של קובץ הtrain הנתון לtrain ו-validation כאשר גודל הvalidation הוא 0.2 מגודל הtrain.

מבנה המודל:

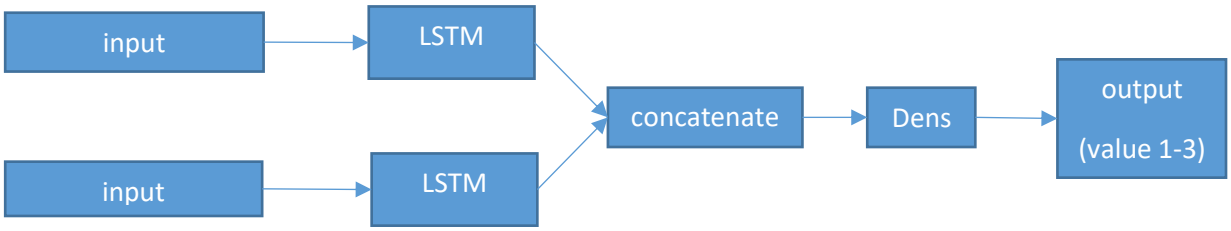

רוני מינדלין מילר 302242870
מיה קרמר 204219976

יש לציין שבמודל יש שכבת LSTM אחת אך היא מקבלת 2 inputs שונים ולכן גם יש לה 2 outputs שונים ולכן המודל משורטט כאילו מדובר ב-2 שכבות שונות שמתמזגות לשכבה אחת (בשלב ה-concatenate). אנו מציינות זאת מאחר וזה לא היה לנו ברור מאילו ולכן אנו חושבות שחשוב לציין זאת.

לאחר אימון הרשת על עם epoch=5 ו-batch_size=72 קיבלנו:

```
Train on 59254 samples, validate on 14813 samples
Epoch 1/5
59254/59254 [==============================] - 104s 2ms/step - loss: 0.3173 - mean_squared_error: 0.3173 - val_los
s: 0.2806 - val_mean_squared_error: 0.2806
Epoch 2/5
59254/59254 [==============================] - 102s 2ms/step - loss: 0.2799 - mean_squared_error: 0.2799 - val_los
s: 0.2807 - val_mean_squared_error: 0.2807
Epoch 3/5
59254/59254 [==============================] - 102s 2ms/step - loss: 0.2790 - mean_squared_error: 0.2790 - val_los
s: 0.2800 - val_mean_squared_error: 0.2800
Epoch 4/5
59254/59254 [==============================] - 102s 2ms/step - loss: 0.2792 - mean_squared_error: 0.2792 - val_los
s: 0.2849 - val_mean_squared_error: 0.2849
Epoch 5/5
59254/59254 [==============================] - 102s 2ms/step - loss: 0.2792 - mean_squared_error: 0.2792 - val_los
s: 0.2810 - val_mean_squared_error: 0.2810
0:08:33.459564
```

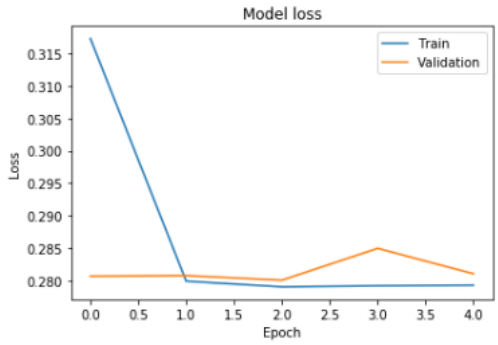

ניתן לראות שיש שיפור בערך ה-loss של ה-train בתהליך הלמידה אך מה שחשוב הוא ה-loss של ה-validation והוא לא משתפר, ומתחיל מערך יחסית נמוך. ננסה לשפר את המודל.

ניסינו להגדיל את מספר הנוירונים בשכבת ה-LSTM מ-50 ל-100 והגדלנו את מספר ה-epoches מ-5 ל-10 אך עדיין אין ירידה משמעותית ובאופן הדרגתי עבור הloss של הvalidation כפי שאנו מצפות לראות:

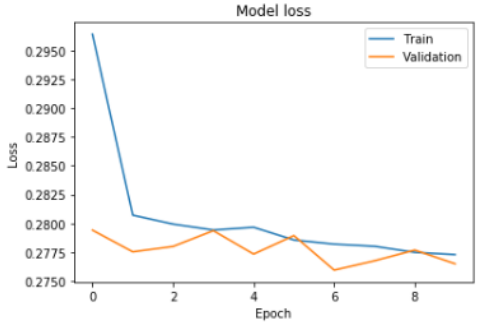

רוני מינדלין מילר 302242870
מיה קרמר 204219976

כעת הסתכלנו על הבעיה ב-2 דרכים שונות עם שיטות ולידציה שונות:

1. בעיית רגרסיה (כפי שהצגנו לעיל) עם k-fold cross validation.

2. בעיית סיווג עם StratifiedKFold - ניתן לעשות זאת מכיוון שמספר הערכים הניתנים במשתנה המטרה relevance שווה ל-13 ערכים שונים אפשריים. הסיבה לכך היא מאופן חישוב הrelevance- נבחרו 3 שופטים לדירוג הרלוונטיות של המוצר לחיפוש שנעשה וה-relevance נקבע לפי ממוצע הדירוגים של 3 השופטים. במקרה זה נשתמש ב-StratifiedKFold כדי לאמוד את ביצועי המודל שלנו כיוון ששיטה זו מבצעת פיצול של הנתונים ל-folds כך שהתפלגות הנתונים ב-folds השונים תהיה זהה להתפלגות הנתונים ב-data המקורי ואכן זה מתאים לבעיה שלנו מאחר ויש imbalance בנתונים כפי שהצגנו בתחילת הדוח.

3. בעיית רגרסיה עם StratifiedKFold - הסיבה שלא השתמשנו ב-StratifiedKFold עבור בעיית הרגרסיה ב-1 היא ששיטת ולידציה זו דורשת שה-class לא יהיה מספר רציף. החלטנו לנסות להשתמש בשיטה זו גם עבור בעיית רגרסיה ע"י המרת y למספרים באמצעות label_encoder רק עבור הפיצול ע"י StratifiedKFold ושימוש בy המקורי עבור אימון המודל.

תוצאות שיטה 1:

שימוש במודל כפי שהוסבר ושורטט לעיל רק שבשכבה האחרונה פונקציית האקטיבציה היא relu ופונקציית ההפסד היא mse.

להלן גרפים המתארים את הloss בכל אחד מחמשת ה-epochs שביצענו:

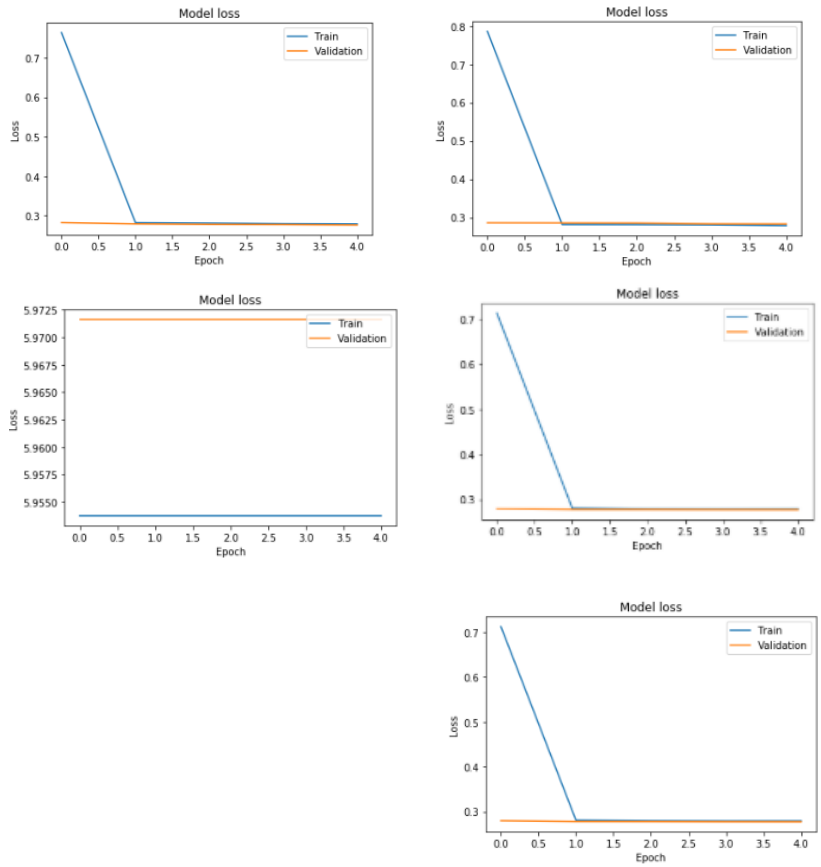

רוני מינדלין מילר 302242870
מיה קרמר 204219976

ניתן לראות שבfold השלישי הloss גרוע מאוד. ההנחה שלנו היא שמאחר והנתונים הם imbalanced אז ספציפית הרשומות שנבחרו עבור הfold הזה אינן טובות בכך שלוקח למודל יותר זמן לעבד אותן ואולי לא ניתן למצוא דפוסים ברשומות אלו בכלל (מאחר וה-loss של הtrain גם לא טוב ולא משתפר).

יש לציין כי בfolds האחרים יש מעט שיפור בloss של הvalidation אך לא רואים זאת בבירור בגרף מאחר ובהתחלה הloss על הtrain היה משמעותית יותר גבוה, לדוגמה פלט של אחד מהfolds שהרצנו:

```
Train on 59253 samples, validate on 14814 samples
Epoch 1/5
59253/59253 [==============================] - 38s 635us/step - loss: 0.7858 - mean_squared_error: 0.7858 - val_loss: 0.2859 - val_mean_squared_error: 0.2859
Epoch 2/5
59253/59253 [==============================] - 36s 608us/step - loss: 0.2813 - mean_squared_error: 0.2813 - val_loss: 0.2855 - val_mean_squared_error: 0.2855
Epoch 3/5
59253/59253 [==============================] - 36s 602us/step - loss: 0.2811 - mean_squared_error: 0.2811 - val_loss: 0.2852 - val_mean_squared_error: 0.2852
Epoch 4/5
59253/59253 [==============================] - 36s 604us/step - loss: 0.2804 - mean_squared_error: 0.2804 - val_loss: 0.2832 - val_mean_squared_error: 0.2832
Epoch 5/5
59253/59253 [==============================] - 36s 601us/step - loss: 0.2785 - mean_squared_error: 0.2785 - val_loss: 0.2829 - val_mean_squared_error: 0.2829
rmse 0.5319170518434212
```

ניתן לראות שקיים שיפור בloss של הvalidation

fold	rmse
1	0.531
2	0.525
3	2.443
4	0.526
5	0.525
mean	0.91

תוצאות שיטה 2:

שימוש במודל כפי שהוסבר ושורטט לעיל רק שבשכבה האחרונה פונקציית האקטיבציה היא softmax, פונקציית ההפסד היא categorical_crossentropy וה-y נתון כ-one-hot:

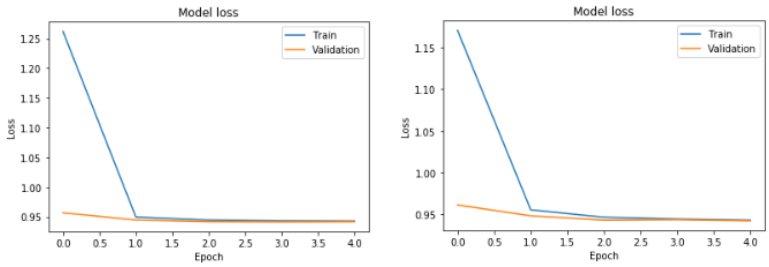

רוני מינדלין מילר 302242870
מיה קרמר 204219976

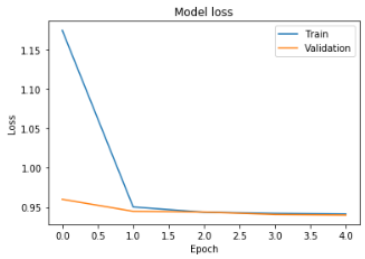

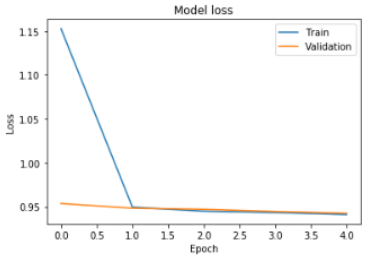

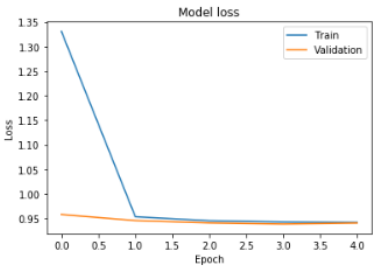

fold	accuracy
1	0.581
2	0.581
3	0.581
4	0.580
5	0.581
mean	0.581

רוני מינדלין מילר 302242870
מיה קרמר 204219976

תוצאות שיטה 3:

שימוש במודל כפי שהוסבר ושורטט לעיל רק שבשכבה האחרונה פונקציית האקטיבציה היא relu ופונקציית ההפסד היא mse.

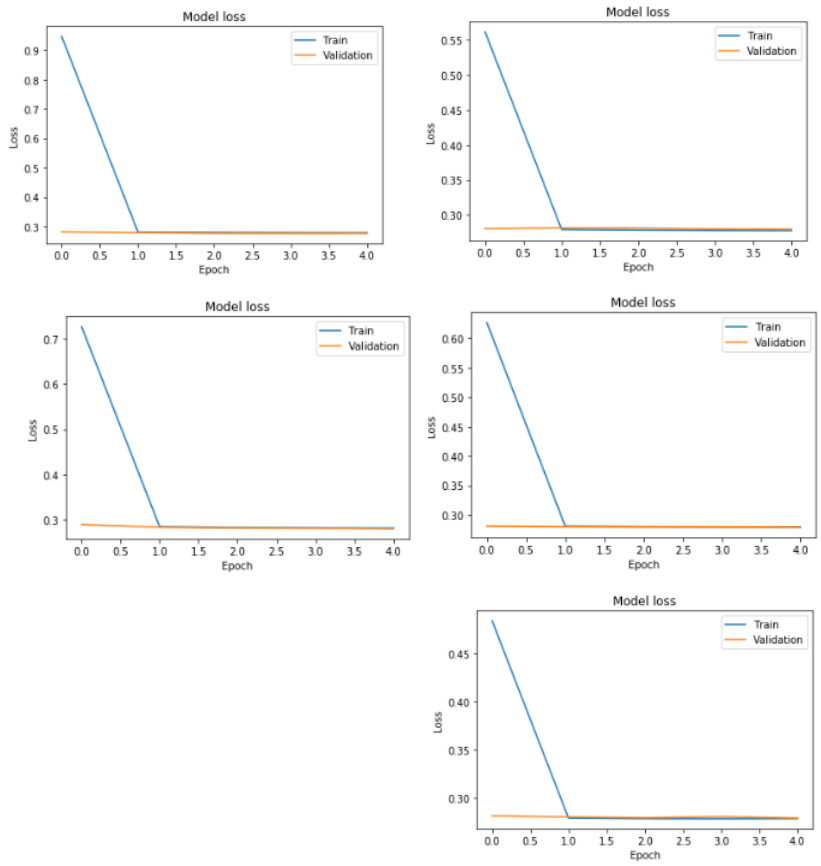

fold	rmse
1	0.528
2	0.529
3	0.528
4	0.528
5	0.526
mean	0.528

ניתן לראות שאכן בשימוש ב-StratifiedKFold עבור בעיית רגרסיה אנו כבר לא מקבלות את המקרה בו ה-loss היה קבוע וגבוה מאוד עבור הtrain והvalidation כפי שראינו במקרה 1 שבו השתמשנו בk-fold וחשדנו שמצב זה התקבל מהחלוקה הלא הוגנת מבחינת ערך המטרה בשימוש בk-fold.

רוני מינדלין מילר 302242870
מיה קרמר 204219976

<u>שיפורים-</u> נמשיך עם הגישה השלישית כלומר התייחסות לבעיה כבעיית רגרסיה ושימוש בשיטת ולידציה StratifiedKFold. יש לציין שהחיזוי הסופי של הtest set יתקבל כממוצע של החיזויים על הtest set בכל אחד מהfolds שביצענו.

ניסנו לשפר את המודל ע"י הוספת שכבת dense עם 50 נוירונים לאחר שכבת הconcat שלאחריו מגיע גם שכבת dropout (עם הסתברות 0.3) על מנת למנוע over fitting ואחרי שכבת הdropout שכבת dense אחרונה שהיא הoutput ולכן היא עם נוירון אחד בלבד. בנוסף הוספנו אחרי שכבת ה-LSTM עוד שכבת של batch normalization.

קיבלנו שה-rmse השתפר במעט. בנוסף הloss של הtrain פחות טוב מה-loss של הvalidation לאורך כל תהליך האימון כתוצאה מהוספת שכבת ה-dropout. דוגמה לepoch אחד בתהליך ה-cross validation:

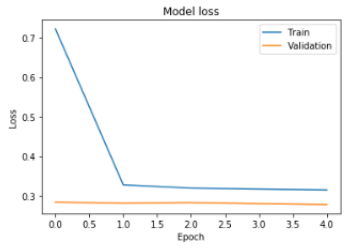


```
Train on 59251 samples, validate on 14816 samples
Epoch 1/5
59251/59251 [==============================] - 32s 535us/step - loss: 0.7220 - val_loss: 0.2844
Epoch 2/5
59251/59251 [==============================] - 27s 463us/step - loss: 0.3280 - val_loss: 0.2816
Epoch 3/5
59251/59251 [==============================] - 27s 462us/step - loss: 0.3197 - val_loss: 0.2832
Epoch 4/5
59251/59251 [==============================] - 28s 464us/step - loss: 0.3173 - val_loss: 0.2804
Epoch 5/5
59251/59251 [==============================] - 27s 462us/step - loss: 0.3152 - val_loss: 0.2781
rmse 0.5273664109699436
```

לכן הקטנו את הdropout ל0.1 ואכן כעת הvalidation והtrain בעלי loss קרוב מאוד:

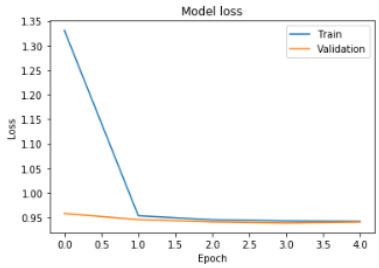

כלומר, המודל הנוכחי שהתקבל:

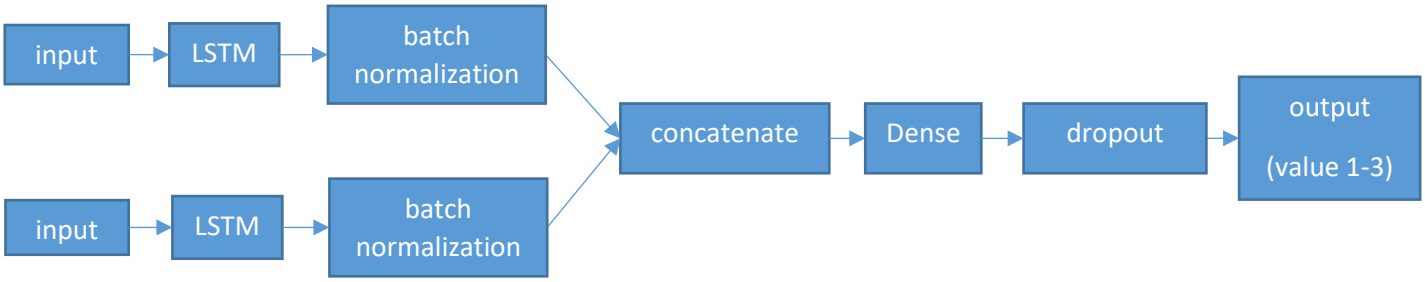

רוני מינדלין מילר 302242870
מיה קרמר 204219976

לאחר קריאת קובץ relevance_instructions הנתון המכיל את ההוראות שניתנו לשופטים על מנת לדרג את הזוגות חיפוש-תוצאה, הבנו שניתן לשופטים דגש מיוחד להתייחס ל-Brand, Material, and Functionality של כל מוצר ולפי זה לדרג את הרלוונטיות תוצאות החיפוש למוצר. לכן החלטנו להוסיף רק את שדות אלו מקובץ attributes.csv אל שדה הtitle של נתוני הtrain והtest. מאחר וכעת האורך המקסימלי של התווים שקיבלנו בשדה הtitle הוא 303, החלטנו שכעת נבצע את הpadding ע"י הממוצע של אורך הtitle ולא ע"י הערך המקסימלי. האורך הממוצע הוא בגודל 66 תווים.

לאחר בחינת תוצאת המודל, הבנו שרוב החיזויים הניתנים הם בטווח קטן יחסית:

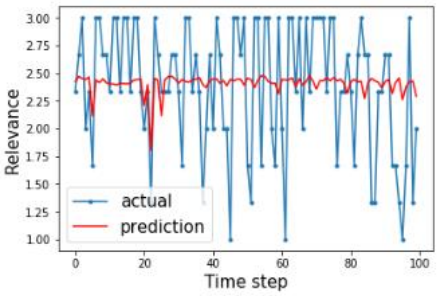

מפה הגענו למסקנה שהמודל לא מצליח לחזות ערכים גדולים\קטנים גם אם מופיעים בשכיחות גבוהה בנתונים כמו למשל דירוג 3- יש לדירוג זה הכי הרבה רשומות (מעל 19000) ועדיין המודל לא חוזה אותו אפילו פעם אחת. החלטנו שיש לנרמל את ערכי הרלוונטיות- נרמלנו ע"י min_max normalization שמביא את ערכי הרלוונטיות לערכים בין 0 ל-1, ובדקנו את התוצאות החדשות:

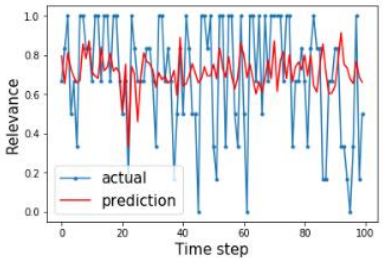

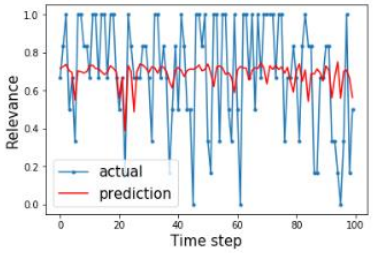

ניתן לראות שאכן טווח חיזוי המודל גדל! ואכן ה-rmse הממוצע השתפר: 0.271 (לא בהכרח שיפור כל כך משמעותי כי צמצמנו את ערכי המטרה ולכן גם טווח השגיאה קטן) **בטבלה הסופית התייחסנו לערכי המטריקות רק לאחר המרת משתנה המטרה חזרה לטווח המספרים המקורי שלהם.**

רוני מינדלין מילר 302242870
מיה קרמר 204219976

כעת הבנו דבר נוסף- המודל נותן חשיבות גדולה יותר לתווים בעלי קידוד מספרי בעל ערך גבוה יותר, למשל אם a מקודד ל-1 ו-z מקודד ל24 אז z מקבל "חשיבות" גבוהה יותר בתהליך האימון. לכן שיננו את הקלט למודל כך שכל char ייצוג לא ע"י הקידוד המספרי שלו אלא ע"י one hot, ולכן אם עד עכשיו המודל היה מקבל קלט במימדים: (n_samples, avg_length, 1) אז עכשיו הקלט למודל יהיה במימדים:

(n_samples, avg_length, n_unique_char).

מאחר והמעבר לone-hot תופס המון מקום בזיכרון לא הצלחנו לבצע יותר מ-2 split עבור 5 epochs כאשר מתייחסים לpadding לאורך הממוצע (66 תווים). העדפנו לוותר על splits מאשר לחתוך יותר תווים מהקלט לאחר בדיקת שיפור הrmse.

תוצאות:

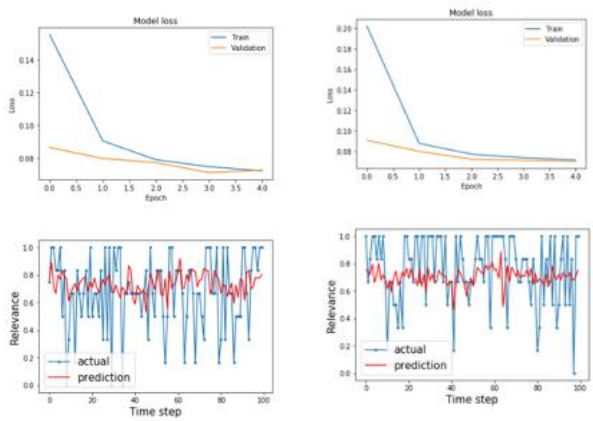


```
mean rmse 0.2670321973538482
end time 246.814
mean train time 68.003
mean pred time 43.9555
```

מכיוון שהkernel נפל כל הזמן ולא הצלחנו לבצע commit במלואו, החלטנו לצמצם את רשימת התווים הייחודים (כמו למשל ?, =, *, !, ועוד), ולבדוק אם הדבר פוגע בrmse ואם כעת יהיה ניתן להריץ את הkernel במלואו:

התווים הייחודים החדשים שהתקבלו:

```
array(['<uniq>', '#', '%', '+', '/', '0', '1', '2', '3', '4', '5', '6',
       '7', '8', '9', 'a', 'b', 'c', 'd', 'e', 'f', 'g', 'h', 'i', 'j',
       'k', 'l', 'm', 'n', 'o', 'p', 'q', 'r', 's', 't', 'u', 'v', 'w',
       'x', 'y', 'z', '°', '²'], dtype='<U6')
```

כעת מספר התווים הייחודים הוא 43.

רוני מינדלין מילר 302242870
מיה קרמר 204219976

תוצאות:

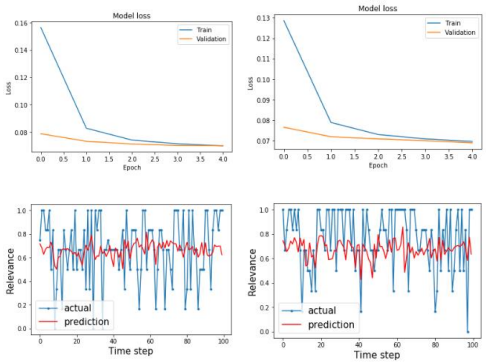


```
mean rmse 0.2627451185252867
end time 347.59
mean train time 108.74549999999999
mean pred time 51.427
```

הrmse אפילו מעט ירד! לכן נמשיך בשיטה זו.

יש לציין שניסינו להשתמש גם ב**SMOTE** על מנת ליצור רשומות מלאכותיות להגדלת סט הנתונים על מנת שהמודל יוכל להתאמן על יותר דוגמאות בעלות דירוג נמוך יחסית (מאחר ויש סיווגים רק עם 4 רשומות למשל ולכן המודל לא לומד מהן בכלל) אך לא הצלחנו להגיע לתוצאות כתוצאה מעומס על הזיכרון מאחר והוספנו רשומות נוספות.

<u>תוצאות הגשה לתחרות:</u>

הגשנו את קובץ הsample submission שיצרנו ע"י קבלת ממוצע הprediction על הtest set מתהליך הcross validation וקיבלנו את התוצאות (בטבלה הסופית מופיעות כל המטריקות שבדקנו):

Siamese net rmse on test set: 0.529

<u>Feature extraction</u>

מודלי הclassic ml שחברנו להשתמש בהם כקלט לתוצאות הfeature extraction הם XGBRegressor ו-LGBMRegressor. מדובר במודלים המבוססים על בניית ensembles של עצי החלטה בצורה איטרטיבית כך שבנייה של כל עץ תלויה בתוצאות של העצים הקודמים שנבנו. ההבדל בין 2 המודלים הנ"ל הוא ש-XGB נבנה בצורת רוחבית (פיתוח כל הקדקודים באותה השכבה ואז עובר לפיתוח השכבה הבאה) לעומת LGBM שנבנה לעומק כלומר פיתוח הקדקודים לעומק- לכן גם יותר מהיר משמעותית וצורך פחות זיכרון.

נחלק את הtrain ל-train ו-val. לאחר אימון המודל על הtrain שהתקבל, שלפנו את השכבה החמישית (שזוהי שכבת הconcat) ונתייחס אליה כפלט של המודל הנועד לקבלת הfeatures. את הקלט של המודל נשאיר כמו שהוא כלומר:

```
concat_layer = siamese_model.layers[5].output
feature_model = Model(siamese_model.input, concat_layer)
feature_model.compile(loss='mse', optimizer='adam')
```

רוני מינדלין מילר 302242870
מיה קרמר 204219976

כעת נחזה את ערך ה-train וערך ה-val ונבדוק את הrmse שיתקבל עבור החיזוי ע"י כל אחד מהמודלים: XGBRegressor ו-LGBMRegressor כאשר הקלט לאותם מודלים הוא הפלט שהתקבל מהמודל feature_model שתיארנו לעיל וערכי ה-relevance המתאימים.

לאחר ביצוע מעט tuning לכל אחד מהמודלים על-פי ערך הrmse שהתקבל עבור ה-validation set, בחרנו את הפרמטרים שהביאו לrmse הנמוך ביותר על הvalidation set, הרצנו את המודלים האלו על כל נתוני ה train set (כדי לקבל את הfeatures באמצעותם נבצע fit) והtest set (כדי לקבל את הfeatures עליהם נבצע predict) בתהליך כפי שתואר לעיל (קודם חילוץ הפיצ'רים ממודל הSiamese ולאחר מכן הכנסתם למודל הml) והגשנו submission של מודלים אלו והתוצאות הן (מופיעות גם בטבלה הסופית ביותר פירוט):

lgb rmse: 0.531

xgb rmse: 0.544

רוני מינדלין מילר 302242870
מיה קרמר 204219976

חלק 2- word embeddings and word level LSTM

את תהליך עיבוד הנתונים ביצענו כפי שתיארנו לעיל (יצירת df_all המכיל את הtitle המורכבת מהשדות title, Brand, Metrial).

כעת השתמשנו בTokenizer של keres על מנת לחלק את המשפטים לtokens, כאשר שינינו את הפילטר של הtokenizer כך שיסנן **רק** את התווים הבאים: !"$&()*+,-.:;<=>?[\]^_`{|}~

לאחר מכן בדקנו מהו אורך המשפט המקסימלי עבור השדות product_title ו-serach_term, לקחנו את המקסימום מבין השניים, ובצענו padding לערך המקסימלי של אפסים בתחילת כל טקסט על מנת שכל הטקסטים יהיו באותו האורך.

כעת השתמשנו ב-GoogleNews-vectors-negative300 כבסיס לembedding שלנו. יצרנו מטריצה בגודל (n_unique_words, embedding_size) המאותחלת בערכים **רנדומליים**, כך שכל שורה בה מייצגת מילה לפי האינדקס של אותה מילה הנוצר ע"י הtokenizer. כעת החלפנו כל שורה במטריצה במשקלים של אותה המילה שקיבלנו מקובץ הembedding של google. המילים הייחודיות שנמצאות במאגר המילים שלנו אך לא נמצאות במאגר המילים של google נותרו עם משקלים אקראיים ובתהליך הלמידה של המודל הם ישתנו ויקבלו ערכים מתאימים. יש לציין שהבחירה הטובה ביותר ליצירת embedding למילים שלנו תהיה לא להשתמש בembedding חיצוני בכלל וללמוד את הembedding של המילים מההתחלה ע"י אימון המודל שלנו וכך נקבל embedding שמתאים ספציפית לבעיה שלנו (קשרים שמופיעים אצלנו ולא הופיעו אצל google ולהפך) אך מפאת חוסר זמן החלטנו להשתמש בembedding של google ולאפשר למודל להתאמן גם על המשקלים (לא קיבענו את שכבת הembedding ל-trainable=false) האלו כלומר נקודת ההתחלה שלנו לא אקראית לחלוטין אך גם לא קבועה לפי google לאורך כל האימון.

כפי שהסברנו בחלק הראשון, נרמלנו את ערכי המטרה באמצעות min_max normalization.

השתמשנו במודל זהה למודל שבנינו בחלק הראשון רק ששינינו את גודל הinput ל-

(n_sampels, max_length, embedding size). גם פה השתמשנו בשיטת הוולידציה StratifiedKFold מאותן סיבות שכבר ציינו.

תוצאות המודל:

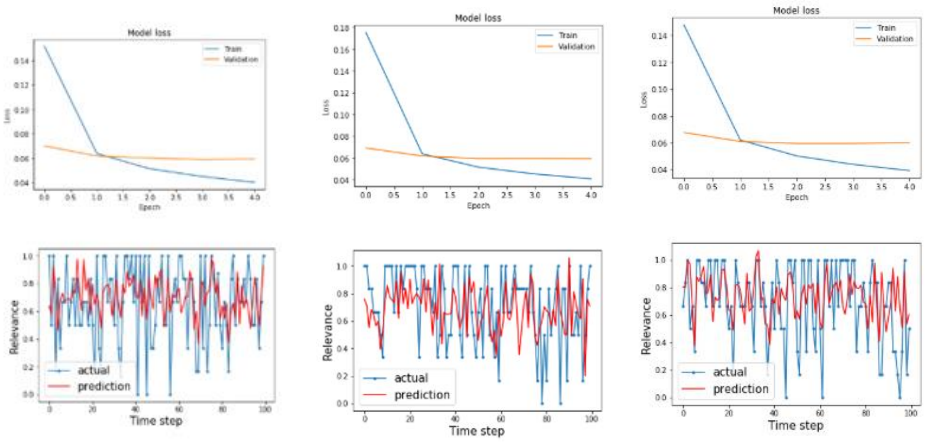

רוני מינדלין מילר 302242870
מיה קרמר 204219976

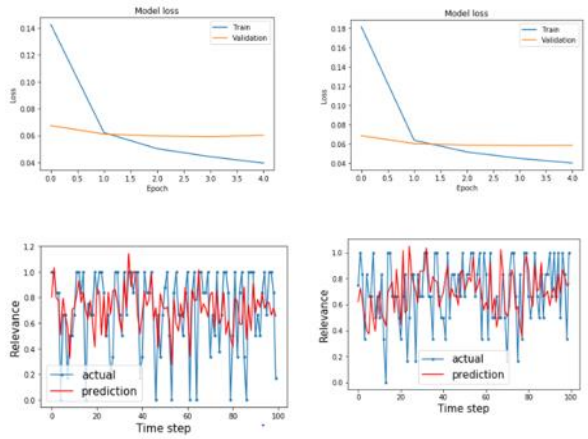

fold	Rmse
1	0.245
2	0.243
3	0.243
4	0.245
5	0.241
mean	0.243

ניתן לראות שה-loss של הvalidation גבוה יותר מהloss של הtrain. אנו חושדות שיש over fit, לכן הגדלנו את הdropout ל-0.5.

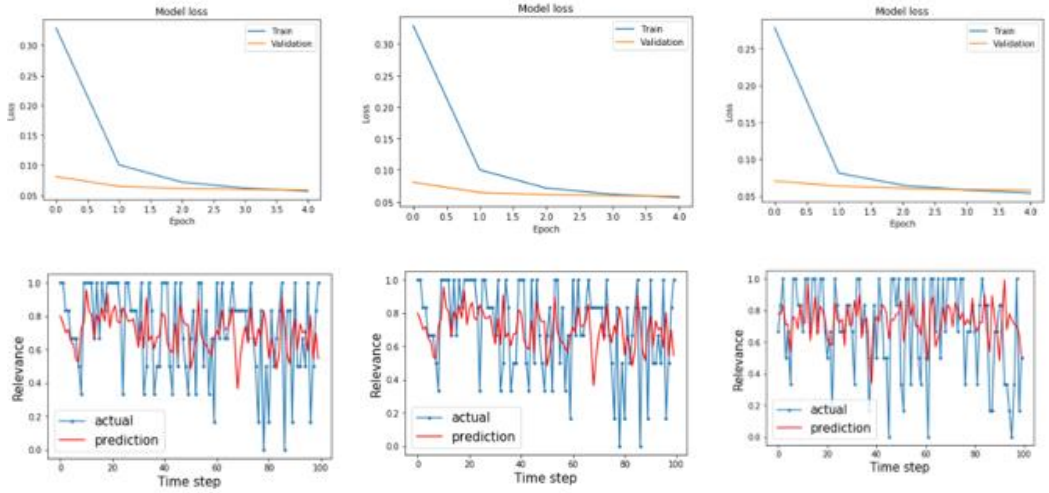

רוני מינדלין מילר 302242870
מיה קרמר 204219976

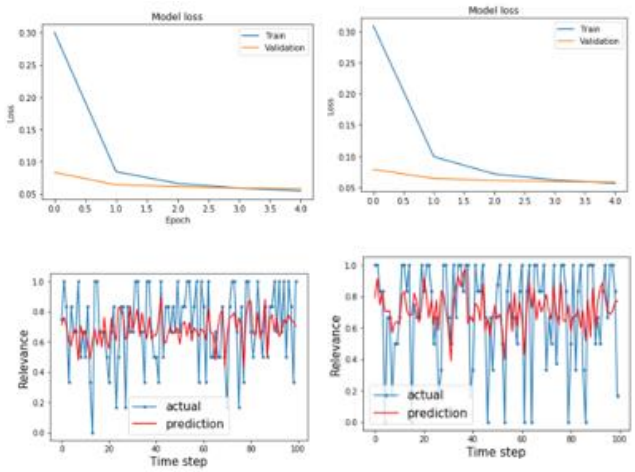

fold	Rmse
1	0.241
2	0.241
3	0.242
4	0.240
5	0.241
mean	0.241

ניתן לראות שכבר אין over fitting וגם ה-rmse מעט עלה.

כעת כשהמודל הגיע לתוצאות הכי טובות שהצלחנו לקבל עד כה על הvalidation, הגשנו הגשה של sample submission על ממוצע הprediction של הtest set שהתקבל לאורך ה-cross validation שביצענו, קיבלנו:

rmse: 0.50774

התוצאה הטובה ביותר שקיבלנו עד כה!!!

<u>Feature extraction</u>

תהליך האימון של מודלי הfeature extraction זהה לתהליך כפי שהצגנו בחלק 1 של העבודה. ביצענו מעט tuning למודלים. תוצאות (תוצאות סופיות נוספות ו-plots בטבלה הסופית):

lgb rmse: 0.520

xgb rmse: 0.535

רוני מינדלין מילר 302242870
מיה קרמר 204219976

סיכום ומסקנות:

Model type	Runtime (second)	Mean train time	Mean test prediction time	Train RMSE	Val-RMSE	Test-RMSE	Train MAE	Val-MAE	Test-MAE
naïve benchmark model- mean relevance train	3.136	1.53	1.606	0.530	0.552	0.536	0.440	0.439	0.441
naïve benchmark model- common characters	19.157	18.11	1.047	0.667	0.787	0.631	0.481	0.622	0.480
naïve benchmark model- common n-grams	21.334	19.520	1.814	0.881	0.728	0.722	0.704	0.584	0.541
Character level LSTM	314.31	101.75	31.61	0.518	0.528	0.529	0.420	0.428	0.432
Character level feature extractor - XGB	15.577	15.223	0.354	0.544	0.544	0.558	0.455	0.455	0.455
Character level feature extractor - LGB	2.774	2.012	0.762	0.531	0.531	0.532	0.436	0.436	0.436
WORD level LSTM	3738.241	619.53	76.50	0.423	0.482	0.507	0.339	0.390	0.413
WORD level feature extractor - XGB	20.395	19.856	0.538	0.518	0.507	0.532	0.436	0.412	0.459
WORD level feature extractor - LGB	4.246	3.228	1.018	0.484	0.521	0.520	0.398	0.415	0.426

*השורה המסומנת זוהי התוצאה הטובה ביותר שקיבלנו.

רוני מינדלין מילר 302242870
מיה קרמר 204219976

<u>plots של המודלים הסופיים:</u>

- Char level:
  - Siamese net **train** (2-stratified folds)

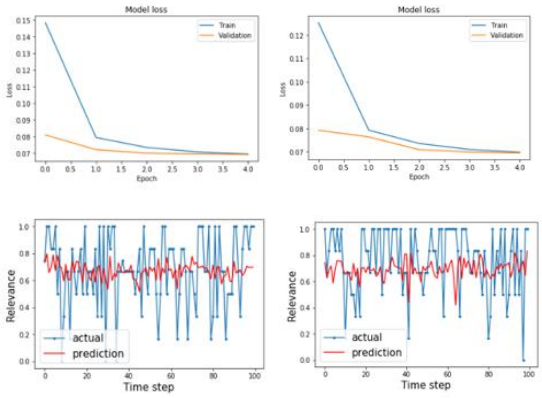

  - Siamese net **validation** (2-stratified folds)

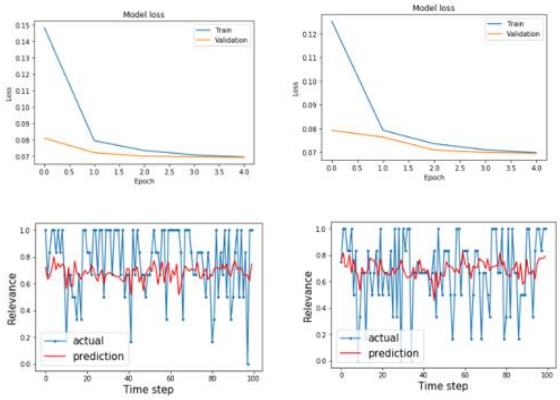

  - Siamese net **test**

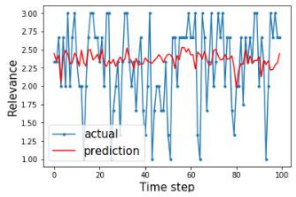

רוני מינדלין מילר 302242870
מיה קרמר 204219976

- feature extraction – XGB
  - test set:

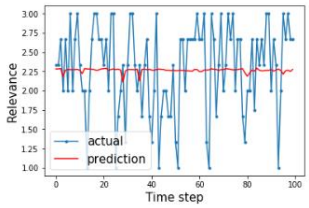

  - train set:

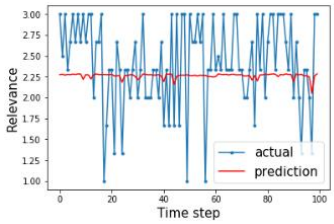

  - validation set:

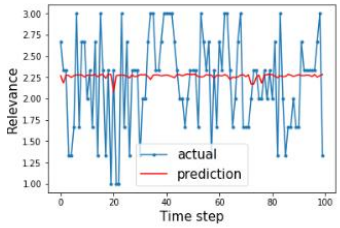

- feature extraction – LGB
  - test set:

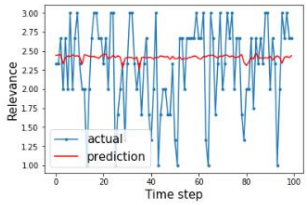

  - train set:

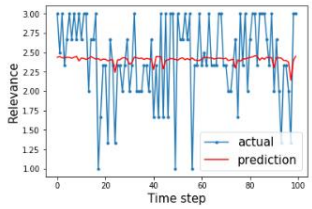

  - validation set:

רוני מינדלין מילר 302242870
מיה קרמר 204219976

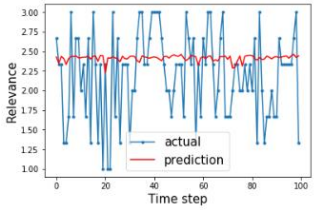

- word level:
  - Siamese net **train**

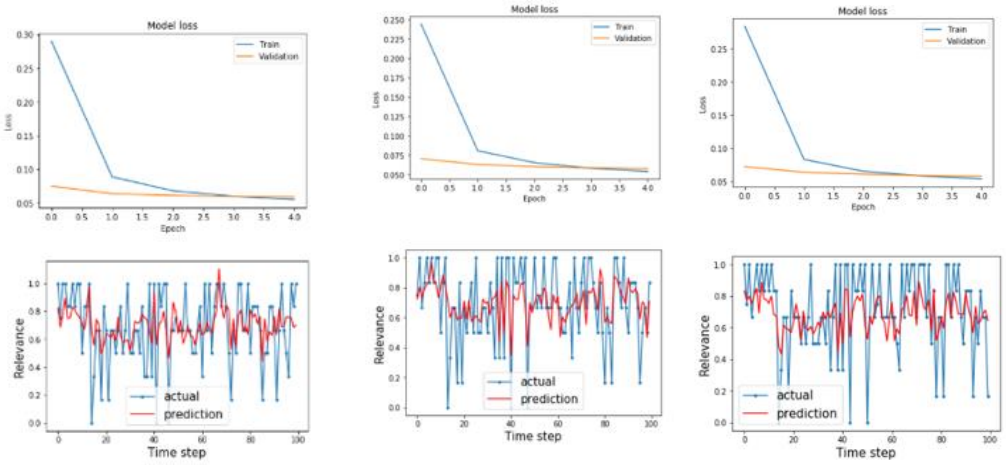

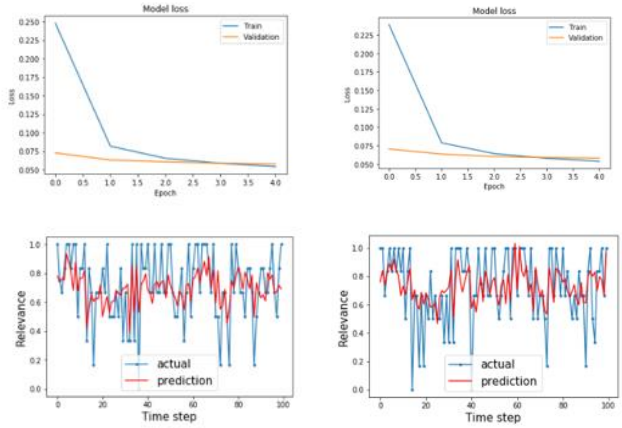

רוני מינדלין מילר 302242870
מיה קרמר 204219976

- Siamese net **validation**

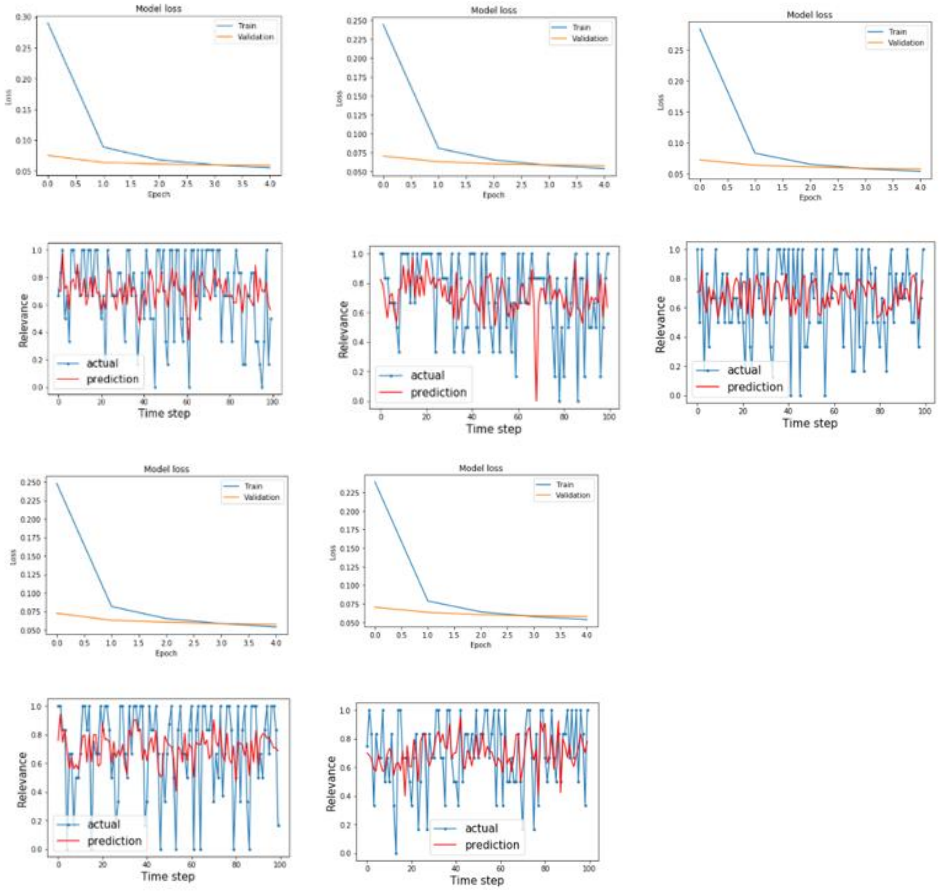

- Siamese net **test**

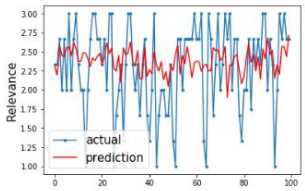

- feature extraction – XGB
  - test set:

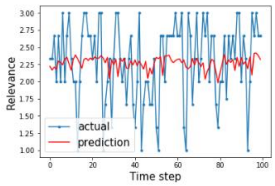

  - train set:

רוני מינדלין מילר 302242870
מיה קרמר 204219976

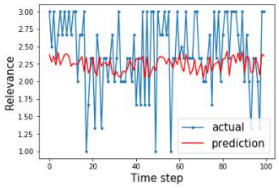

- validation set:

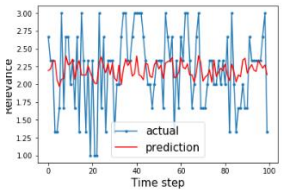

- feature extraction – LGB
  - test set:

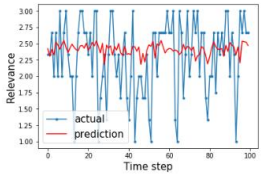

  - train set:

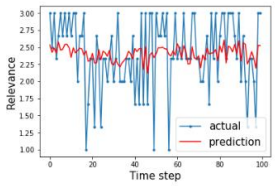

  - validation set:

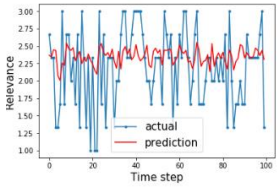

רוני מינדלין מילר 302242870
מיה קרמר 204219976

רעיונות לפיתוח אפשרי (חלקם ניסינו אך כתוצאה מהגבלה בזיכרון לא הצלחנו לממש):

- ביצוע embedding מאפס (ללא שימוש בembedding מוכן חיצוני) על מנת להתאים כמה שיותר את הembedding לבעיה שלנו.
- שימוש בGAN, SMOTE או יוצר רשומות מלאכותיות אחר כלשהו על מנת לאזן את המחלקות בבעיה.
- הוספת המידע הנתון בטבלת product description על מנת לתת יותר מידע למודל על כל מוצר.

מסקנות:

השימוש בword level טוב יותר עבור המשימה הנוכחית מאשר השימוש בchar level. אנו סבורות כי ניתן לשפר את התוצאות ע"י הרעיונות שהצענו לעיל ולא מימשנו כתוצאה של חוסר זמן אך בעיקר חוסר באמצעים (**זיכרון**). בעבודה הזאת ההבנה המשמעותית ביותר הייתה בנושא של פונקציות האקטיבציה בשכבות המודל- גם בעבודות אחרות היינו צריכות לשנות את פונקציית האקטיבציה בהתאם למשימה אך פה מאחר וניסינו את 2 האפשרויות (חיזוי או סיווג) ממש ראינו כיצד טעות בבחירת פונקציות האקטיבציה של שכבות המודל עשויה להשפיע על כל התוצאות והיינו צריכות להתאים כל פעם את המודל לסוג המשימה. בנוסף הבנה משמעותית נוספת שקיבלנו היא התאמת מבנה הקלט והפלט לסוג המשימה. ביצענו reshape לא מעט פעמים לקלט המודל על מנת להתאימו למודל שלנו- בהתחלה הכנסנו את הקלט ללא one hot ולכן המימד השלישי של הקלט היה צריך להיות 1 ולקח לנו זמן להבין זאת (למרות שזה ברור מאילו- לא הבנו למה המודל לא מצליח לקבל את מבנה הקלט שהזנו ללא ביצוע reshape) ורק לאחר שהמודל זרק שגיאה הבנו שיש לבצע reshape לממדים:

(n_sampels, avg_n_charcters_in_text, 1). לאחר ביצוע one hot או embedding גם היינו צריכות לשנות את מבנה הקלט למודל אך כעת כבר היה לנו יותר ברור מהם המימדים שצריכים להזין בשכבת הinput.

לסיכום, ניסינו מודלים שונים ומגוונים וניסינו להתייחס לבעיה מזוויות שונות על מנת לבחון כיצד ניתן להגיע לתוצאות הטובות ביותר מבלי לקבל over fitting ואכן בחלק מהניסיונות שלנו הצלחנו לשפר את תוצאות המודל.